Processamento e Análise de Imagens

Classificação

Prof. Alexei Machado
PUC Minas

O Processo de Visão Computacional Clássico

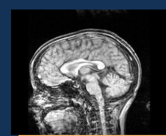

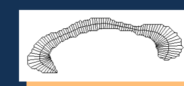

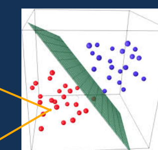

AQUISIÇÃO → PROCESS. → SEGMENTAÇÃO → DESCRIÇÃO → CLASSIFICAÇÃO → classe

BAIXO NÍVEL

ALTO NÍVEL

- Sensores
- Am. espacial
- Am. espectral
- Perda de info.
- Aliasing

- Filtrar elementos indesejáveis
- Realçar desejados
- Dom. do espaço X Dom. da frequência

- Particionar a imagem em objetos
- Problema sem solução geral

- Região X Contorno
- Seleção de caract.
- Redução de dimensionalidade

- Classificadores
- Distância X Similaridade
- Estatística, IA

Funções de Decisão

- Determinar uma função que fundamente a decisão de atribuir um padrão a uma das classes do problema

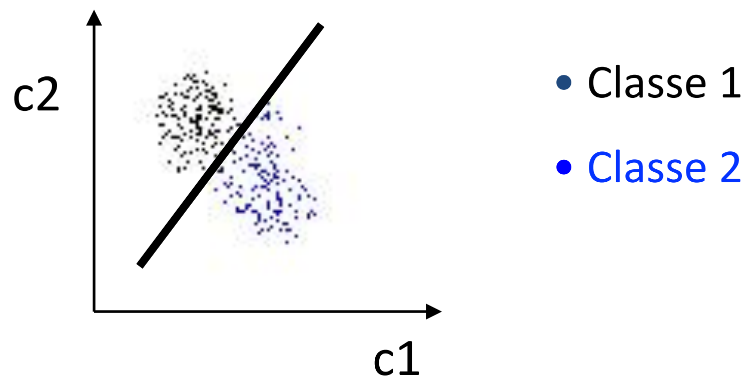

Funções de Decisão

Questões:

- As características permitem boa separabilidade das classes?
- As classes são linearmente separáveis?
- A distribuição das classes é Normal?
- As distribuições têm covariâncias semelhantes?
- As características são independentes?

Funções de Decisão

Relação entre os descritores

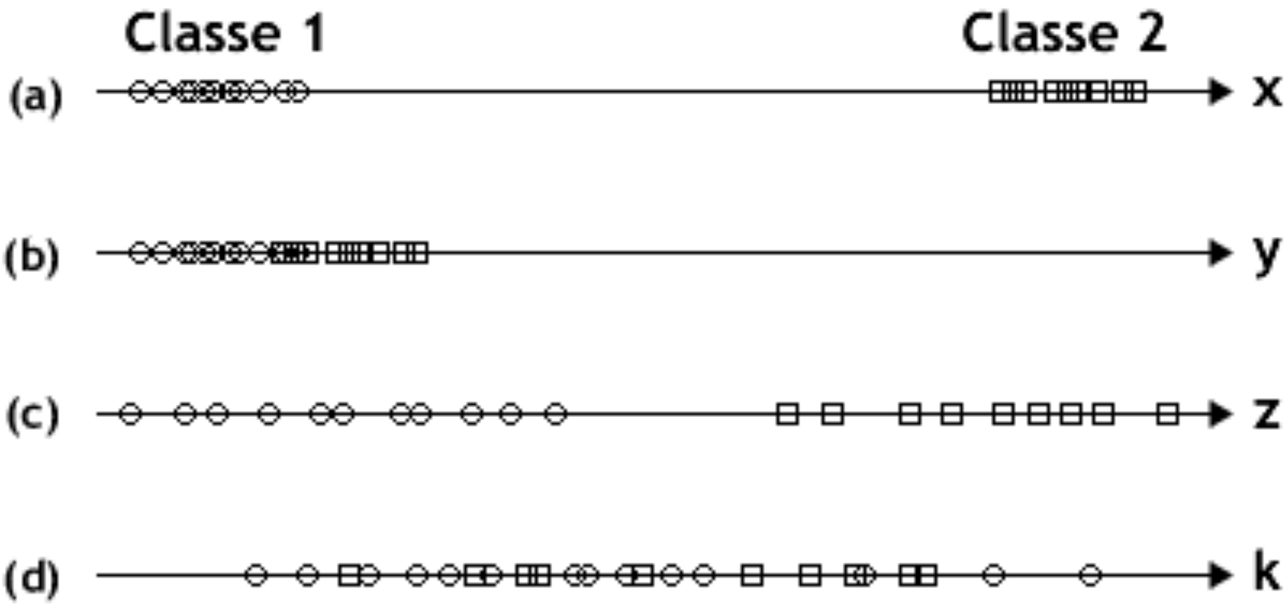

Ideal: Médias afastadas com desvio padrão pequeno.

Funções de Decisão

Problemas Multi-classe

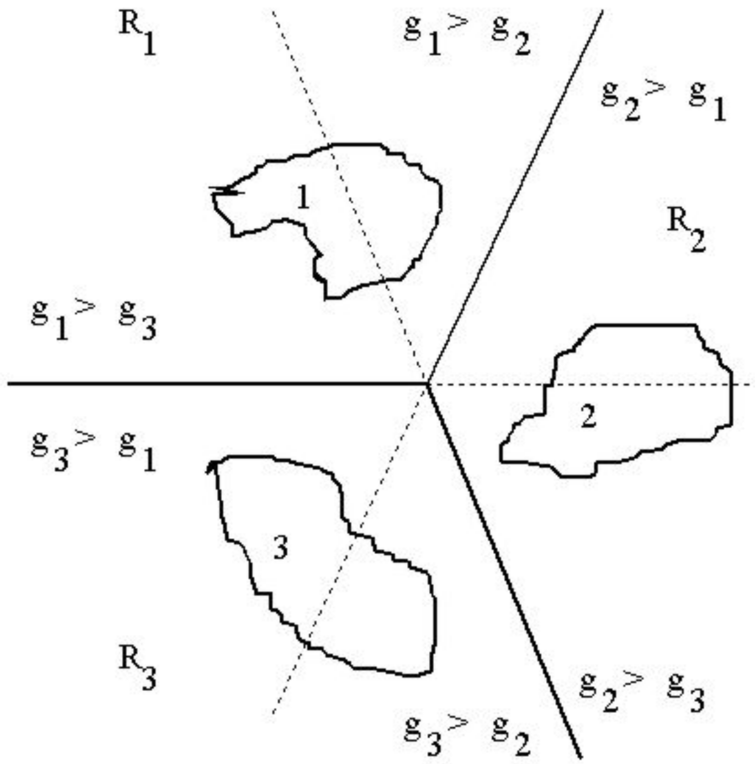

Classificadores Não-paramétricos

Vizinho mais próximo (KNN)

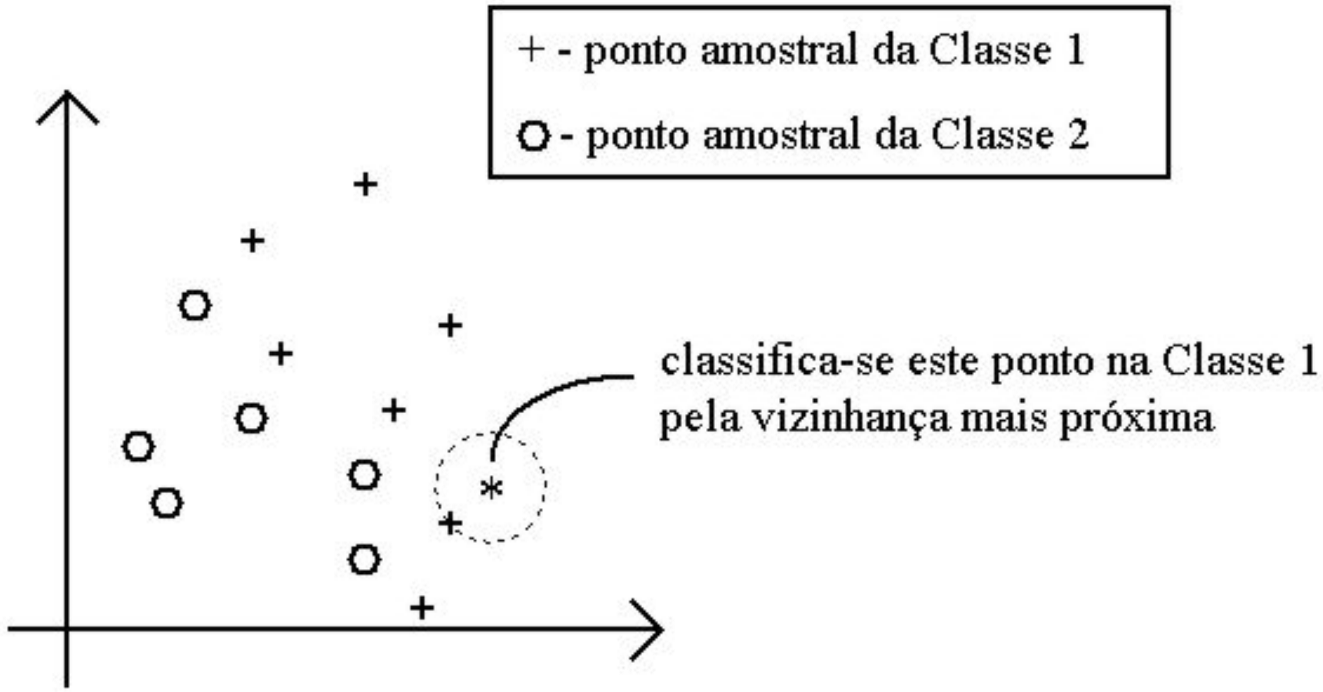

Classificação Supervisionada Paramétrica

Etapas:

- Escolher um conjunto de treinamento. Cada elemento do conjunto tem sua classe determinada.
- Escolher características discriminantes.
- Escolher um método/função de decisão.
- Determinar os parâmetros a partir do conjunto de treino.
- Testar com objetos fora do conjunto de treinamento.

Métricas de Desempenho

Problemas com 2 classes:

- Falso positivo (FP): Sistema que detecta quadrados diz que uma imagem de um triângulo é um quadrado.
- Verdadeiro positivo (TP): Sistema que detecta quadrados diz que uma imagem de um quadrado é um quadrado.
- Falso negativo (FN): Sistema que detecta quadrados diz que uma imagem de um quadrado não é um quadrado.
- Verdadeiro negativo (TN): Sistema que detecta quadrados diz que uma imagem de algo que não é quadrado não é um quadrado.

Métricas de Desempenho

Problemas com 2 classes:

- Acurácia = (TP+TN)/(TP+TN+FP+FN)
- Sensibilidade ou Revocação = TP/(TP+FN)
- Especificidade = TN/(TN+FP)
- Precisão = TP/(TP+FP)
- Escore F1 ou Dice = 2TP/(2TP+FP+FN)

Métricas de Desempenho

Problemas com múltiplas classes: Matriz de confusão

Obj \ Classe	Círculo	Quadrado	Triângulo
Círculo	10	2	1
Quadrado	5	20	2
Triângulo	0	0	10

Árvores de Decisão

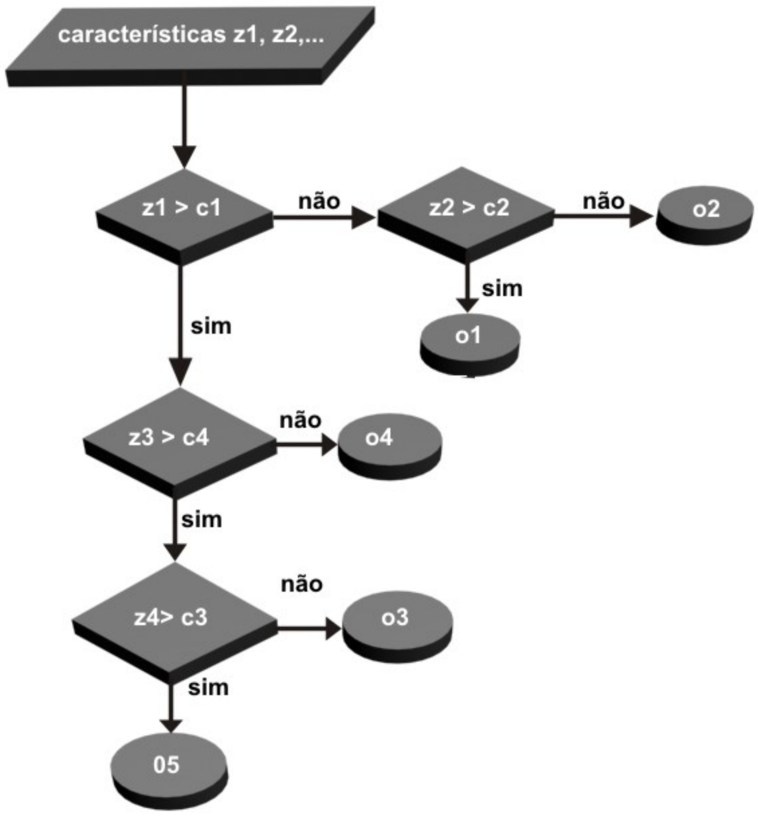

Distância Euclidiana

Dados dois vetores P e Q

$$P = (p_1, p_2, \ldots, p_n)$$

$$Q = (q_1, q_2, \ldots, q_n)$$

a distância Euclidiana entre eles é de

$$\sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2} = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}.$$

Distância Euclidiana

Função de decisão:

O padrão **x** pertence a classe c_i com média $\mathbf{m}_i$ se

$$\sqrt{(\mathbf{x}-\mathbf{m}_i)^T(\mathbf{x}-\mathbf{m}_i)} < \sqrt{(\mathbf{x}-\mathbf{m}_j)^T(\mathbf{x}-\mathbf{m}_j)}, \forall i \neq j$$

Distância de Mahalanobis

Distingue-se da distância Euclidiana já que leva em conta as correlações entre as características e diferenças de unidades

Ex: classificar um peixe baseado no seu comprimento e altura

- Vetor (x1, x2), sendo x1 comprimento e x2 altura
- Comprimento varia entre 50 e 100cm, altura entre 10 e 20cm

Caso 1: Calcular a distância Euclidiana entre o peixe e a média de cada classe

Ruim, pois dá a mesma importância para o comprimento e para altura – mas o comprimento varia muito mais que a altura

$$d_e(\vec{x_1}\vec{x_2}) = \sqrt{(x_{11} - x_{12})^2 + (x_{21} - x_{22})^2}$$

Distância de Mahalanobis

Caso 2: Incluir a media de dispersão de cada variável (comprimento e altura), e a variância para cada característica

$$d_2(\vec{x_1}\vec{x_2}) = \sqrt{\left(\frac{(x_{11} - x_{12})}{\sigma_1}\right)^2 + \left(\frac{(x_{21} - x_{22})}{\sigma_2}\right)^2}$$

Ruim, pois existe uma correlação entre altura e comprimento: um salmão mais comprido sofre também uma mudança na sua altura

Caso 3: Incluir a covariância entre x_1 e x_2:

$$d_m(\vec{x_1}\vec{x_2}) = \sqrt{(\vec{x}_1 - \vec{x}_2)^T \Sigma^{-1} (\vec{x}_1 - \vec{x}_2)}$$

Distância de Mahalanobis

Amostra com *N* objetos:

$$D_i(\mathbf{x}) = (\mathbf{x} - \mathbf{m}_i)^T \mathbf{C}_i^{-1} (\mathbf{x} - \mathbf{m}_i)$$

$$C_i[j,k] = \sum_{s=1}^{N} \frac{(\mathbf{x}_s[j] - \mathbf{m}_i[j])(\mathbf{x}_s[k] - \mathbf{m}_i[k])}{N-1}$$

Função de decisão: O padrão **x** pertence a classe c_i com média $\mathbf{m}_i$ e matrix de covariância $\mathbf{C}_i$ se

$$D_i(\mathbf{x}) < D_j(\mathbf{x}), \forall i \neq j$$

Classificador de Bayes

Inclui a probabilidade a priori de cada classe.

$$d_i(\mathbf{x}) = \ln P(c_i) - \frac{1}{2}\ln|\mathbf{C}_i| - \frac{1}{2}(\mathbf{x}-\mathbf{m}_i)^T \mathbf{C}_i^{-1}(\mathbf{x}-\mathbf{m}_i)$$